Sistem Klasifikasi Aduan Telyu Fess Berbasis Large Language Model dengan Prompt Engineering untuk Mendukung Direktorat Penunjang Akademik

Shaquille Rayhannizam Wibisono
Program Studi Sarjana Sistem Informasi
Direktorat Kampus Surabaya, Universitas Telkom
Surabaya, Indonesia
line 5: alamat email atau ORCID

Berlian Rahmy Lidiawaty
Program Studi Sarjana Sistem Informasi
line 3: *nama organisasi*
Direktorat Kampus Surabaya, Universitas Telkom
Surabaya, Indonesia
line 5: alamat email atau ORCID

Agus Sulistya
Program Studi Sarjana Sistem Informasi
line 3: *nama organisasi*
Direktorat Kampus Surabaya, Universitas Telkom
Surabaya, Indonesia
line 5: alamat email atau ORCID

***Abstrak*—** Aduan mahasiswa di media sosial mengandung informasi layanan yang bernilai, tetapi bentuknya tidak terstruktur dan sulit dipilah secara manual ke unit yang bertanggung jawab. Penelitian ini mengembangkan model klasifikasi teks berbasis Large Language Model (LLM) menggunakan prompt engineering serta sistem berbasis Flask sebagai artefak pendukung. Dataset terdiri atas 1.100 teks ground truth dari akun X Telyu Fess periode 2023–2025 yang dikelompokkan ke tujuh direktorat penunjang akademik. Tiga LLM lokal, yaitu Qwen3-4B-Instruct, Meta-Llama-3.1-8B-Instruct, dan Komodo-7B, diuji menggunakan lima konfigurasi prompt (K1–K5) dengan kombinasi format keluaran, aturan, keyword list, few-shot examples, dan aturan prioritas. Evaluasi menggunakan accuracy, weighted precision, weighted recall, weighted F1-score, reliabilitas, serta karakteristik teknis inferensi. Hasil terbaik diperoleh Meta-Llama-3.1-8B-Instruct dengan K2, yaitu accuracy 86,1%, weighted precision 87,2%, weighted recall 86,1%, dan weighted F1-score 85,8%. Seluruh model mencapai konsistensi 100% pada sepuluh pengulangan. Keyword list memberikan manfaat terbesar pada Llama, terbatas pada Qwen, dan cenderung menurunkan performa Komodo. Hasil menunjukkan bahwa performa tidak ditentukan secara tunggal oleh banyak atau sedikitnya konteks prompt, melainkan oleh kesesuaian struktur prompt dengan karakteristik model.

Kata kunci— LLM, prompt engineering, klasifikasi teks, few-shot prompting, Telyu Fess, Flask

I. PENDAHULUAN

Perkembangan Natural Language Processing (NLP) berbasis arsitektur Transformer memperluas kemampuan sistem dalam memahami teks tidak terstruktur dan menjalankan berbagai tugas bahasa tanpa pipeline fitur yang dirancang secara khusus [1], [2]. Large Language Model (LLM) memanfaatkan kemampuan tersebut untuk menerima instruksi berbasis teks dan menghasilkan respons sesuai konteks. Pada tugas klasifikasi, LLM dapat digunakan tanpa melakukan fine-tuning dengan cara mendeskripsikan label, aturan keputusan, format keluaran, serta contoh klasifikasi secara langsung di dalam prompt. Pendekatan ini membuat perubahan kategori dan aturan klasifikasi dapat dilakukan melalui rekayasa konteks, bukan melalui pelatihan ulang parameter model.

Prompt engineering menjadi aspek penting karena keluaran LLM dipengaruhi oleh struktur dan kejelasan instruksi. Prompt dapat memuat tugas, pembatasan, format keluaran, informasi kategori, daftar kata kunci, serta contoh masukan-keluaran. Few-shot prompting secara khusus menyediakan beberapa contoh representatif sehingga model memperoleh pola klasifikasi melalui in-context learning [3], [4]. Literatur terbaru juga menunjukkan bahwa penambahan konteks tidak selalu menghasilkan peningkatan performa secara linear; konteks yang tidak relevan atau instruksi yang terlalu padat dapat mengalihkan perhatian model dari informasi utama [5], [6]. Oleh karena itu, konfigurasi prompt perlu diuji secara empiris terhadap model dan dataset yang digunakan.

Di lingkungan perguruan tinggi, aduan mahasiswa merupakan sumber informasi yang dapat mendukung evaluasi layanan. Namun, aspirasi tidak selalu disampaikan melalui kanal resmi. Media sosial masih digunakan mahasiswa untuk menyampaikan pengalaman, kritik, dan kebutuhan akademik [7]. Aduan elektronik di media sosial juga menuntut respons yang terarah karena isu dapat berkaitan dengan layanan yang berbeda [8]. Pada Telkom University, akun X Telyu Fess memuat unggahan anonim mengenai proses akademik, fasilitas, pembayaran, teknologi informasi, sumber daya manusia, serta aktivitas kemahasiswaan. Data tersebut berpotensi menjadi sumber evaluasi, tetapi format teks yang informal, penggunaan singkatan, dan tumpang tindih konteks antarlayanan membuat pengelompokan manual tidak efisien.

Studi terdahulu pada data Telyu Fess telah menggunakan Naïve Bayes untuk klasifikasi topik terkait bidang rektorat [9], sedangkan penelitian lain menggunakan pendekatan berbasis leksikon untuk analisis sentimen umpan balik mahasiswa [10]. Pemanfaatan LLM pada domain pendidikan juga telah berkembang untuk analisis teks dan klasifikasi [11], tetapi penerapan prompt engineering untuk mengarahkan aduan mahasiswa ke direktorat penunjang akademik masih terbatas. Perbedaan utama penelitian ini terletak pada pengembangan model prompt sebagai artefak utama, perbandingan tiga LLM lokal dengan lima konfigurasi prompt, analisis pengaruh keyword list, serta integrasi model ke sistem Flask untuk menjalankan klasifikasi dan evaluasi. [10 pts]

Penelitian ini bertujuan mengembangkan model klasifikasi berbasis LLM menggunakan prompt engineering, mengevaluasi kinerja kombinasi model dan prompt menggunakan metrik klasifikasi yang sesuai untuk dataset tidak seimbang, serta mengimplementasikan artefak dalam sistem berbasis Flask. Kontribusi utamanya adalah konfigurasi K2 yang menggabungkan format keluaran, keyword list, dan few-shot examples, beserta bukti empiris bahwa kompleksitas prompt tidak memiliki hubungan monoton dengan akurasi. Dengan demikian, jumlah konteks yang lebih banyak tidak otomatis menghasilkan klasifikasi yang lebih baik, dan prompt yang lebih ringkas juga tidak selalu menjadi pilihan optimal

II. KAJIAN TEORI

A. Large Language Model Dan Prompt Engineering

LLM merupakan model bahasa berbasis Transformer yang dilatih pada korpus berskala besar untuk mempelajari pola sintaksis, semantik, dan hubungan kontekstual antartoken. Pada klasifikasi teks, LLM tidak harus menghasilkan uraian panjang; keluaran dapat dibatasi menjadi satu label yang dipilih dari himpunan kategori yang telah ditentukan. Kemampuan mengikuti instruksi menjadi relevan karena model harus memetakan teks aduan ke struktur organisasi yang tidak selalu dapat ditentukan hanya dari kemunculan kata tertentu. Perbedaan keluarga model, ukuran parameter, data pelatihan, dan proses instruction tuning dapat menyebabkan respons yang berbeda terhadap prompt yang sama.

Prompt engineering adalah proses merancang instruksi dan konteks agar perilaku LLM sesuai dengan tujuan tugas [3], [5]. Komponen prompt dalam penelitian ini mencakup instruksi aturan, daftar direktorat, instruksi larangan, format keluaran, keyword list, few-shot examples, aturan prioritas, dan teks masukan. Keyword list diposisikan sebagai konteks pendukung, bukan aturan deterministik. Hal ini penting karena istilah seperti “tahap akhir studi”, “BPP”, “LMS”, atau “dosen” dapat muncul bersama dalam satu aduan dan merepresentasikan lebih dari satu unit layanan.

B. Few-shot Prompting dan Klasifikasi Teks

Few-shot prompting memberikan contoh pasangan teks dan label di dalam prompt agar model mengenali pola penyelesaian tugas tanpa mengubah parameter internal [4]. Dalam konteks klasifikasi aduan, contoh berfungsi sebagai referensi hubungan antara inti permasalahan dan direktorat yang bertanggung jawab. Pendekatan tersebut berbeda dari klasifikasi machine learning konvensional yang biasanya memerlukan preprocessing, representasi fitur, proses training, serta retraining ketika struktur kelas berubah.

Evaluasi klasifikasi multikelas menggunakan accuracy, precision, recall, dan F1-score. Karena distribusi data penelitian tidak seimbang, weighted precision, weighted recall, dan weighted F1-score digunakan agar kontribusi tiap kelas dipertimbangkan sesuai jumlah datanya [12]. Weighted F1-score dijadikan indikator utama pemilihan kombinasi karena menyeimbangkan ketepatan dan kelengkapan prediksi, sedangkan confusion matrix digunakan untuk mengidentifikasi pola salah klasifikasi antar-direktorat.

C. Design Science Research Methodology

Design Science Research Methodology (DSRM) digunakan karena penelitian menghasilkan artefak yang dirancang untuk menyelesaikan permasalahan praktis dan dievaluasi secara sistematis. DSRM menempatkan identifikasi masalah, penetapan tujuan solusi, perancangan dan pengembangan, demonstrasi, evaluasi, serta komunikasi sebagai rangkaian pengembangan artefak [13]. Pada penelitian ini, model prompt engineering merupakan artefak utama. LLM berfungsi sebagai mesin inferensi, sedangkan aplikasi Flask menjadi artefak pendukung untuk mengelola prompt, menjalankan klasifikasi, menyimpan hasil, dan menampilkan evaluasi.

III. METODE

A. Data dan Ground Truth

Data berasal dari unggahan akun X Telyu Fess periode 2023–2025. Proses persiapan meliputi pengumpulan data, pembersihan atribut yang tidak digunakan, seleksi unggahan yang benar-benar berupa aduan, anotasi direktorat, validasi label, serta penyusunan dataset akhir. Setiap teks diberi satu label berdasarkan inti permasalahan dan unit yang memiliki tanggung jawab utama. Tujuh label yang digunakan adalah Direktorat Akademik; Direktorat Pascasarjana dan Advance Learning; Direktorat Aset dan Sustainability; Direktorat Keuangan; Direktorat Sumber Daya Manusia; Direktorat Pusat Teknologi Informasi; serta Direktorat Kemahasiswaan, Pengembangan Karir, dan Alumni.

TABEL I DISTRIBUSI DATASET GROUND TRUTH

Direktorat	Jumlah
Direktorat Akademik	474
Aset dan Sustainability	25
Sumber Daya Manusia	28
Kemahasiswaan, Pengembangan Karir, dan Alumni	315
Keuangan	126
Pascasarjana dan Advance Learning	11
Pusat Teknologi Informasi	121
Total	1.100

Dataset ground truth berjumlah 1.100 teks. Sebanyak 31 sampel yang mewakili tujuh kategori diperiksa pada proses validasi; 30 label dinilai sesuai dan satu label dikoreksi sebelum dataset digunakan sebagai data acuan. Distribusi kelas tidak seimbang, sehingga evaluasi akhir tidak hanya mengandalkan accuracy. Pemrosesan teks dilakukan secara konservatif: atribut yang tidak diperlukan dihapus dan unggahan nonaduan diseleksi, tetapi informasi semantik yang menentukan tujuan layanan dipertahankan. Pendekatan ini penting karena singkatan, istilah kampus, serta bahasa informal merupakan bagian dari konteks yang harus dibaca LLM. Ground truth kemudian digunakan sebagai acuan yang sama pada seluruh 15 skenario agar perbedaan skor dapat dikaitkan dengan kombinasi model dan prompt, bukan dengan perubahan sampel evaluasi.

B. Model LLM dan Konfigurasi Prompt

Tiga model digunakan sebagai mesin inferensi, yaitu Qwen3-4B-Instruct, Meta-Llama-3.1-8B-Instruct, dan Komodo-7B. Model dijalankan secara lokal melalui llama-cpp-python. Penggunaan model lokal dipilih agar eksperimen dapat dikontrol pada lingkungan komputasi yang sama dan

agar konfigurasi prompt dapat diuji tanpa ketergantungan pada layanan eksternal. Parameter inferensi menggunakan temperature rendah dan seed tetap untuk menekan variasi keluaran; konfigurasi perangkat disesuaikan dengan kebutuhan model.

Model prompt dirancang modular. Base template, daftar tujuh direktorat, dan teks masukan digunakan pada seluruh konfigurasi, sedangkan enam komponen eksperimen dikombinasikan menjadi K1–K5. K1 memuat instruksi aturan, larangan, format keluaran, keyword list, dan few-shot examples. K2 hanya memuat format keluaran, keyword list, dan few-shot examples. K3 memuat instruksi aturan, format keluaran, dan few-shot examples. K4 merupakan konfigurasi paling lengkap karena menambahkan aturan prioritas ke komponen K1. K5 memuat instruksi aturan, larangan, dan format keluaran tanpa keyword list maupun few-shot examples. Kombinasi lima prompt dengan tiga LLM menghasilkan 15 skenario evaluasi.

C. Prosedur Evaluasi

Evaluasi dilakukan pada empat aspek. Pertama, validasi ground truth memastikan label acuan sesuai dengan ruang lingkup direktorat. Kedua, reliabilitas operasional diuji dengan menjalankan satu teks, prompt, dan parameter yang sama sebanyak sepuluh kali pada masing-masing model; konsistensi dinilai dari kesamaan label. Ketiga, performa teknis mengukur waktu total klasifikasi 1.100 teks, rata-rata waktu per teks, penggunaan RAM puncak, dan VRAM puncak dengan prompt K1. Keempat, evaluasi akhir membandingkan prediksi 15 skenario terhadap ground truth menggunakan accuracy, weighted precision, weighted recall, dan weighted F1-score.

TABEL II KONFIGURASI PROMPT

Komponen	K1	K2	K3	K4	K5
Instruksi aturan	✓	–	✓	✓	✓
Instruksi larangan	✓	–	–	✓	✓
Format keluaran	✓	✓	✓	✓	✓
Keyword list	✓	✓	–	✓	–
Few-shot examples	✓	✓	✓	✓	–
Aturan prioritas	–	–	–	✓	–

Pemilihan kombinasi terbaik memprioritaskan weighted F1-score, kemudian accuracy, precision, recall, konsistensi keluaran, pola confusion matrix, dan efisiensi teknis. Analisis keyword list dilakukan secara deskriptif dengan membandingkan rata-rata weighted F1-score konfigurasi yang memuat keyword list (K1, K2, K4) terhadap konfigurasi tanpa keyword list (K3, K5). Perbandingan ini digunakan untuk mengidentifikasi kecenderungan respons tiap model, bukan untuk menyatakan hubungan kausal yang tidak diuji secara terpisah.

D. Implementasi Sistem Flask

Aplikasi berbasis Flask mengintegrasikan antarmuka pengguna, pengelolaan prompt, dataset, mesin inferensi LLM, basis data, modul evaluasi, serta ekspor hasil. Pengguna dapat memilih model dan konfigurasi prompt, mengunggah dataset, menjalankan klasifikasi, memantau proses, serta mengunduh hasil dalam format tabular. Prompt Manager digunakan untuk mengubah komponen prompt tanpa memodifikasi kode utama. Modul evaluasi membandingkan hasil prediksi dengan ground truth dan menampilkan metrik serta confusion matrix. Pemanfaatan aplikasi web untuk mengoperasionalkan prompt engineering pada konteks layanan Telkom University juga telah digunakan pada pengembangan chatbot berbasis LLM [14]; pada penelitian ini fungsi web diarahkan khusus untuk eksperimen klasifikasi, pengelolaan konfigurasi, dan evaluasi terukur. Arsitektur ini menempatkan model prompt sebagai mekanisme utama pengambilan keputusan, sedangkan sistem web berfungsi sebagai media operasional dan dokumentasi eksperimen.

IV. HASIL DAN PEMBAHASAN

A. Distribusi Data dan Reliabilitas

Distribusi dataset menunjukkan dominasi Direktorat Akademik sebanyak 474 teks dan Direktorat Kemahasiswaan, Pengembangan Karir, dan Alumni sebanyak 315 teks, sedangkan Direktorat Pascasarjana dan Advance Learning hanya memiliki 11 teks. Ketimpangan ini membuat accuracy saja tidak cukup untuk menilai model karena prediksi pada kelas dominan dapat memberikan kontribusi besar terhadap skor keseluruhan. Oleh sebab itu, weighted F1-score digunakan bersama metrik lain untuk mengevaluasi keseimbangan kinerja pada seluruh dataset.

Uji reliabilitas menghasilkan konsistensi 100% untuk Qwen3-4B-Instruct, Meta-Llama-3.1-8B-Instruct, dan Komodo-7B. Masing-masing model menghasilkan label yang sama pada sepuluh pengulangan dengan teks, prompt, dan parameter yang identik. Hasil ini menunjukkan bahwa konfigurasi inferensi yang digunakan cukup stabil untuk evaluasi komparatif. Reliabilitas tersebut merupakan konsistensi operasional keluaran, bukan reliabilitas instrumen psikometrik.

Ketidakseimbangan kelas juga memengaruhi cara hasil dibaca. Kelas Akademik dan Kemahasiswaan mencakup sebagian besar data, sedangkan Pascasarjana dan Advance Learning hanya memiliki 11 teks. Karena weighted F1-score memberi bobot sesuai dukungan tiap kelas, nilai agregat tetap lebih dipengaruhi kelas besar. Dengan demikian, skor 85,8% pada konfigurasi terbaik harus ditafsirkan sebagai kinerja keseluruhan yang kuat pada distribusi data aktual, bukan sebagai bukti bahwa seluruh direktorat memiliki tingkat keberhasilan identik. Pemeriksaan confusion matrix tetap diperlukan untuk menilai kelas minoritas dan kasus lintas-konteks.

B. Pengaruh Konfigurasi Prompt terhadap Kinerja

Evaluasi 15 skenario memperlihatkan variasi performa yang besar pada model yang sama. Meta-Llama-3.1-8B-Instruct menghasilkan weighted F1-score 78,8% pada K1, meningkat menjadi 85,8% pada K2, turun menjadi 71,6% pada K3, kembali meningkat menjadi 81,8% pada K4, dan turun tajam menjadi 49,0% pada K5. Pada Qwen3-4B-Instruct, hasil terbaik diperoleh K1 dengan 75,4%, sedangkan K4 turun menjadi 42,1%. Komodo-7B menunjukkan pola berbeda karena performa terbaik justru diperoleh K5 dengan 66,2%.

Pola tersebut menegaskan bahwa akurasi prompt tidak ditentukan oleh banyak atau sedikitnya konteks informasi secara tunggal. K4 merupakan konfigurasi paling lengkap, tetapi tidak menghasilkan skor terbaik secara konsisten. K2 yang lebih ringkas menjadi konfigurasi terbaik

pada Llama, sementara K5 yang paling sederhana relatif lebih sesuai untuk Komodo. Dengan kata lain, hubungan antara kompleksitas prompt dan kinerja bersifat nonmonoton. Penambahan konteks dapat membantu ketika informasi tersebut relevan dengan cara model mengikuti instruksi, tetapi dapat menurunkan performa ketika aturan tambahan, kata kunci, dan prioritas saling berkompetisi dalam perhatian model. Temuan ini selaras dengan pembahasan context engineering bahwa kualitas dan relevansi konteks lebih penting daripada panjang konteks semata [15].

TABEL III HASIL EVALUASI AKHIR

Model	K	Acc.	Prec.	Rec.	F1
Qwen3	K1	74,7	77,3	74,7	75,4
Qwen3	K2	71,5	74,8	71,5	71,9
Qwen3	K3	64,5	64,6	64,5	64,4
Qwen3	K4	43,3	49,3	43,3	42,1
Qwen3	K5	52,6	65,6	52,6	53,7
Llama3	K1	78,0	82,3	78,0	78,8
Llama3	K2	86,1	87,2	86,1	85,8
Llama3	K3	72,2	75,9	72,2	71,6
Llama3	K4	81,6	82,1	81,6	81,8
Llama3	K5	50,7	49,0	50,7	49,0
Komodo	K1	62,3	70,0	62,3	61,8
Komodo	K2	54,5	69,6	54,4	57,4
Komodo	K3	65,3	70,0	65,3	63,3
Komodo	K4	58,6	67,8	58,6	58,6
Komodo	K5	68,4	65,8	68,4	66,2

Kombinasi terbaik seluruh eksperimen adalah Meta-Llama-3.1-8B-Instruct dengan K2. Konfigurasi tersebut menghasilkan accuracy 86,1%, weighted precision 87,2%, weighted recall 86,1%, dan weighted F1-score 85,8%. K2 hanya menyediakan struktur keluaran, keyword list, dan few-shot examples tanpa instruksi aturan yang panjang. Hasil ini mengindikasikan bahwa Llama mampu menggunakan kata kunci sebagai anchor kategori dan memanfaatkan contoh sebagai pola keputusan, sementara ruang inferensi tetap cukup untuk mempertimbangkan makna keseluruhan aduan.

Kontribusi K2 bukan sekadar menghasilkan nilai tertinggi, tetapi menunjukkan bentuk prompt minimum yang efektif untuk model terpilih pada domain ini. Dibandingkan K1, K2 menghapus instruksi aturan dan larangan namun meningkatkan weighted F1-score Llama sebesar 7,0 poin. Dibandingkan K4, K2 juga menghilangkan aturan prioritas dan tetap unggul 4,0 poin. Perbandingan tersebut memberikan bukti empiris bahwa informasi yang relevan dan terstruktur dapat lebih bernilai daripada akumulasi aturan. Namun, kesimpulan ini bersifat task-specific karena Komodo justru mencapai hasil terbaik pada K5 dan Qwen pada K1.

C. Perbandingan Antar-LLM

Model terbaik tidak sama pada setiap konfigurasi. Meta-Llama-3.1-8B-Instruct memberikan performa tertinggi secara keseluruhan dan mencapai skor terbaik pada K2. Qwen3-4B-Instruct mencapai performa terbaik pada K1 dengan accuracy 74,7% dan weighted F1-score 75,4%. Komodo-7B mencapai hasil terbaik pada K5 dengan accuracy 68,4% dan weighted F1-score 66,2%. Perbedaan tersebut menunjukkan bahwa kemampuan memahami bahasa Indonesia saja tidak cukup untuk menjamin klasifikasi organisasi yang akurat. Tugas ini juga memerlukan instruction following, kemampuan membedakan kategori yang berdekatan, dan konsistensi menghasilkan format label yang telah ditentukan.

Analisis confusion matrix memperlihatkan potensi salah klasifikasi ketika satu aduan mengandung indikator dari dua direktorat. Contohnya, kalimat mengenai semester akhir dapat memuat istilah “mata kuliah” atau “tahap akhir studi” yang mengarah ke Akademik sekaligus “bayar” atau “BPP” yang mengarah ke Keuangan. Kasus seperti ini membutuhkan pemahaman mengenai inti masalah, bukan sekadar pencocokan kata. Aturan prioritas pada K4 dirancang untuk menangani konflik tersebut, tetapi hasilnya menunjukkan bahwa tambahan aturan tidak selalu membantu. Pada Qwen, K4 justru menjadi konfigurasi terendah. Hal ini memperkuat kebutuhan untuk mengevaluasi aturan konflik secara empiris dan mempertahankan prompt sesederhana mungkin tanpa menghilangkan konteks yang benar-benar diskriminatif.

D. Performa Teknis

TABEL IV PERFORMA TEKNIS LLM PADA 1.100 TEKS

Model	K	Menit	dtk/teks	RAM %	VRAM %
Qwen3	K1	205,3	11,20	93	73
Llama3	K1	25,6	1,40	71	80
Komodo	K1	106,4	5,80	86	97

Perbandingan teknis memperlihatkan bahwa ukuran parameter bukan prediktor langsung terhadap waktu inferensi. Qwen3-4B-Instruct memerlukan 205,3 menit untuk memproses 1.100 teks atau sekitar 11,20 detik per teks. Meta-Llama-3.1-8B-Instruct memerlukan 25,6 menit atau sekitar 1,40 detik per teks, sedangkan Komodo-7B memerlukan 106,4 menit atau sekitar 5,80 detik per teks. Dari sisi memori, Qwen mencatat RAM puncak 93% dan VRAM 73%; Llama 71% dan 80%; sedangkan Komodo 86% dan 97%

Dalam lingkungan pengujian ini, Meta-Llama-3.1-8B-Instruct tidak hanya memberikan weighted F1-score tertinggi, tetapi juga waktu inferensi paling singkat. Hasil tersebut tidak dapat digeneralisasikan ke seluruh perangkat karena kinerja teknis dipengaruhi kuantisasi, ukuran berkas, pemanfaatan GPU, dan konfigurasi runtime. Namun, untuk artefak yang diuji, Llama memberikan trade-off terbaik antara kualitas klasifikasi dan efisiensi. Temuan ini juga menunjukkan bahwa pemilihan LLM untuk implementasi lokal perlu mempertimbangkan kualitas dan efisiensi secara bersamaan, bukan hanya jumlah parameter.

E. Pengaruh Keyword List

TABEL V PENGARUH KEYWORD LIST

Model	Dengan	Tanpa	Selisih
Qwen3	63,1	59,1	+4,1
Llama3	82,1	60,3	+21,8
Komodo	59,3	64,8	−5,5
Rata-rata	68,2	61,4	+6,8

Keyword list digunakan pada K1, K2, dan K4. Jika weighted F1-score dirata-ratakan, Qwen memperoleh sekitar 63,1% pada konfigurasi dengan keyword list dan 59,1% tanpa keyword list, atau peningkatan sekitar 4,1 poin. Llama memperoleh 82,1% dengan keyword list dan 60,3% tanpa keyword list, atau peningkatan 21,8 poin. Sebaliknya, Komodo memperoleh sekitar 59,3% dengan keyword list dan 64,8% tanpa keyword list, sehingga terjadi penurunan sekitar

5,5 poin. Secara keseluruhan, konfigurasi dengan keyword list mencapai rata-rata 68,2%, dibandingkan 61,4% tanpa keyword list.

Manfaat keyword list dengan demikian bersifat model-specific. Llama memanfaatkannya secara kuat, Qwen memperoleh manfaat terbatas dan sensitif terhadap penambahan aturan prioritas, sedangkan Komodo cenderung lebih baik tanpa daftar kata kunci. Pada Komodo, kata kunci diduga dapat meningkatkan ketergantungan pada token tertentu ketika satu aduan mengandung beberapa indikator kategori. Interpretasi ini bersifat deskriptif karena tidak dilakukan uji ablasi terpisah terhadap representasi internal model. Implikasi praktisnya adalah keyword list sebaiknya diperlakukan sebagai komponen yang perlu divalidasi, bukan sebagai fitur yang diasumsikan selalu meningkatkan akurasi.

F. Artefak Flask dan Implikasi

Sistem Flask berhasil mengoperasionalkan model prompt dengan menyediakan pemilihan LLM, konfigurasi prompt, unggah dataset, proses klasifikasi, Prompt Manager, evaluasi, serta ekspor hasil. Keberadaan Prompt Manager penting karena perubahan struktur prompt merupakan bagian utama eksperimen. Konfigurasi dapat diubah tanpa memodifikasi kode inferensi sehingga sistem mendukung pengujian ulang ketika definisi kategori, keyword list, atau contoh few-shot diperbarui. Sistem ini merupakan artefak pendukung; kontribusi metodologis utama tetap terletak pada model prompt dan hasil evaluasi lintas-LLM.

Hasil penelitian menunjukkan dua implikasi. Pertama, LLM lokal dapat digunakan sebagai classifier berbasis instruksi untuk teks aduan tanpa fine-tuning, tetapi performanya sangat bergantung pada kesesuaian prompt dengan karakteristik model. Kedua, pengelompokan otomatis sebaiknya diposisikan sebagai mekanisme triase awal, bukan pengganti verifikasi manusia, khususnya pada aduan ambigu dan kelas dengan jumlah data sangat kecil. Pengembangan berikutnya dapat memperluas sumber data, menyeimbangkan representasi kelas, menguji LLM lokal yang lebih baru, serta menambahkan Retrieval-Augmented Generation (RAG) agar definisi layanan dan kebijakan kampus dapat diperbarui tanpa memasukkan seluruh informasi ke prompt statis.

V. KESIMPULAN

Penelitian ini menghasilkan model prompt engineering untuk mengklasifikasikan 1.100 teks aduan Telyu Fess periode 2023–2025 ke tujuh direktorat penunjang akademik menggunakan tiga LLM lokal dan lima konfigurasi prompt. Kombinasi terbaik adalah Meta-Llama-3.1-8B-Instruct dengan K2 yang memuat format keluaran, keyword list, dan few-shot examples, dengan accuracy 86,1%, weighted precision 87,2%, weighted recall 86,1%, dan weighted F1-score 85,8%. Seluruh LLM menunjukkan konsistensi 100% pada sepuluh pengulangan. Analisis konfigurasi membuktikan bahwa banyak atau sedikitnya konteks informasi bukan penentu tunggal akurasi; konfigurasi yang lebih kompleks tidak otomatis lebih baik. Keyword list memberi peningkatan terbesar pada Llama, manfaat terbatas pada Qwen, dan cenderung menurunkan performa Komodo. Sistem berbasis Flask berhasil mengintegrasikan pengelolaan prompt, klasifikasi, evaluasi, dan ekspor hasil sebagai artefak pendukung. Penelitian selanjutnya disarankan menguji model yang lebih baru, memperbaiki ketidakseimbangan kelas, melakukan ablasi komponen prompt yang lebih terkontrol, dan memanfaatkan RAG untuk memasukkan informasi layanan yang dinamisr.

REFERENSI

[1] S. Amiruzzaman and M. Amiruzzaman, “Use of Twitter among College Students for Academics: A Mixed-Methods Approach,” Social Sciences, vol. 11, no. 9, 2022, doi: 10.3390/socsci11090404.

[2] L. F. Yee, O. A. Ling, and K. J. Wern, “A systematic review on communication tactics: Dealing with e-complaints on social media,” SEARCH Journal of Media and Communication Research, 2023. [Online]. Available: https://fslmjournals.taylors.edu.my/search/133

[3] M. Hafiz, B. Ibrahim, A. Dzulkarnain, and A. Rausanfita, “Penggunaan Metode Naïve Bayes untuk Klasifikasi Topik Tweet Bidang dan Non-Bidang Rektorat Telkom University pada Akun Telyufess,” Bulletin of Computer Science Research, vol. 5, no. 5, pp. 876–885, 2025, doi: 10.47065/bulletincsr.v5i5.705.

[4] R. Firdaus, I. A., and A. Herdiani, “Lexicon-Based Sentiment Analysis of Indonesian Language Student Feedback Evaluation,” 2021, doi: 10.34818/indojc.2021.6.1.408.

[5] F. S. Alamsyah, A. Sulistya, and B. R. Lidiawaty, “Pengembangan Aplikasi Chatbot Customer Service berbasis Web Menggunakan LLM dengan Metode Prompt Engineering Studi Kasus SSC Telkom University Surabaya,” e-Proceeding of Engineering, pp. 0–15, 2025.

[6] T. Lin, Y. Wang, X. Liu, and X. Qiu, “A survey of transformers,” AI Open, vol. 3, pp. 111–132, 2022, doi: 10.1016/j.aiopen.2022.10.001.

[7] A. Vaswani et al., “Attention Is All You Need,” 2017.

[8] G. Marvin, N. Hellen, D. Jjingo, and J. Nakatumba-Nabende, “Prompt Engineering in Large Language Models,” pp. 387–402, 2024, doi: 10.1007/978-981-99-7962-2_30.

[9] T. B. Brown et al., “Language Models are Few-Shot Learners,” 2020.

[10] A. Drechsler and A. Hevner, “Knowledge Paths in Design Science Research,” Foundations and Trends in Information Systems, vol. 6, no. 3, pp. 171–243, 2022, doi: 10.1561/2900000028.

[11] P. Sahoo, A. K. Singh, S. Saha, V. Jain, S. Mondal, and A. Chadha, “A Systematic Survey of Prompt Engineering in Large Language Models: Techniques and Applications,” arXiv:2402.07927, 2025.

[12] M. Sokolova and G. Lapalme, “A systematic analysis of performance measures for classification tasks,” Information Processing and Management, vol. 45, no. 4, pp. 427–437, 2009, doi: 10.1016/j.ipm.2009.03.002.